

생성형 AI를 활용한 개인화 아동 동화 오디오

서비스 구현

[마이보이스스토리 for 키즈] 최종보고서

AI 기반의 목소리 복제 기술과 LLM 동화 파이프라인 연동 중심 연구

과목명: 생성형 AI의 이해와 활용

소속: 서강대학교 AI SW 대학원

제출자: 9조 (김국희 · 김현정 · 최지은)

제출일자: 2026년 5월 31일

I. 프로젝트 개요 (Project Overview)

1.1 서비스 정의 및 핵심 가치

본 프로젝트는 부모 및 보호자의 목소리를 AI 기술로 복제하여, 아이에게 다양한 동화를 해당 보호자의 목소리로 읽어주는 모바일 웹 기반의 육아 지원 서비스이다. "엄마·아빠 목소리로, 자기 전 아이에게 동화 한 편"이라는 슬로건 아래, 보호자가 시간적·공간적 제약으로 인해 자리에 없더라도 목소리를 통해 언제나 아이 곁에 머무는 듯한 감성적 가치를 전달하고자 한다.

1.2 시스템 문제 정의 및 해결 방향

- 바쁜 현대 부모의 시간 부족: 매일 직접 동화를 충분히 읽어줄 물리적 시간이 부족한 문제를 해결하기 위해, 30초~1분의 짧은 녹음만으로 장편의 동화 오디오를 자동 생성하는 파이프라인을 구축한다.
- 시중 오디오 콘텐츠의 심리적 거리감: 기존 동화 앱의 성우 목소리가 주지 못하는 부모 목소리만의 심리적 안정감과 유대감을 AI 기술로 재현하여 아동의 발달심리학적 애착 형성을 돕는다.
- 오디오 플랫폼의 개인화 공백: 기존 시장의 서비스들이 제공하지 못하는 '우리 가족 맞춤형 목소리'라는 개인화 가치를 고품질 오픈 API 연동을 통해 구현한다.

1.3 PoC 검증 범위 및 시스템 목표


본 최종보고서는 시스템의 실효성을 검증하기 위해 네이티브 앱 개발을 배제하고, 반응형 모바일 웹 환경에서 '동화 선택 → 목소리 녹음 → AI 복제 → 동화 재생'으로 이어지는 핵심 4단계 엔드투엔드(End-to-End) 플로우를 안정적으로 구현하는 것을 목표로 한다.

II. 시스템 아키텍처 및 생성형 AI 파이프라인

2.1 End-to-End 데이터 흐름도 (System Architecture)

본 시스템은 노코드 및 바이브 코딩 프레임워크를 기반으로 하며, 프론트엔드와 백엔드 인프라, AI API가 유기적으로 메시지를 교환하는 구조를 가진다.

- Frontend: Bolt.new 기반 모바일 웹앱 (Vercel 배포)
- Database: Supabase (사용자 정보, 목소리 ID, 동화 텍스트 DB 관리)
- Automation Server: Make (Integromat) — Webhook 수신 및 API 오케스트레이션
- AI Engine: ElevenLabs API (eleven_multilingual_v2), Claude/Cursor AI
- Storage: Cloudflare R2 (최종 생성된 오디오 파일 보관)



2.2 AI 기반 동화 콘텐츠 DB 자동화 파이프라인

Supabase의 stories 테이블에 저장될 동화 콘텐츠 DB는 Claude 기반의 4단계 AI 파이프라인을 통해 자동 구축 및 스크리닝되었다.

단계	입력	AI 처리 기법	출력
1. 소스 수집 & 추천	연령대 및 상황 키워드	Zero-shot Knowledge Elicitation을 통해 퍼블릭 도메인 기반 동화 후보군 발굴	제목, 원작자, 추천 사유 JSON 데이터
2. 아동 언어 재작성	퍼블릭 도메인 원문	Zero-shot Prompting을 기반으로 연령별 발달 수준에 맞춘 텍스트 변환	연령대별(3~5세, 6~8세, 9~11세) 재편집 텍스트
3. 교훈 태깅 & 요약	편집 완료된 동화 전문	Few-shot 및 Chain-of-Thought (CoT) 추론을 통한 태그 매핑 및 글자 수 제한 요약문 생성	교훈 태그 배열, 앱 UI 카드용 소개 요약문
4. 품질 검증	최종 생성된 동화 텍스트	LLM-as-Judge 독립 인스턴스를 통한 아동 적합성, 언어 수준, 교육 가치 평가	항목별 품질 점수(1~5점) 및 재생성 플래그

핵심 프롬프팅 전략 적용 근거

- Few-shot Prompting (교훈 태깅): 교훈 분류는 주관적 성격이 강해 Zero-shot 수행 시 결과 편차가 크므로, 명확한 예시 3~5개를 주입하여 일관된 태그 분류 기준을 확립함.
- Chain-of-Thought (CoT): '동화의 주제 파악 → 주인공의 행동 분석 → 교훈 추론 → 최종 태그 매핑' 단계를 명시하여 단순 분류 대비 복잡한 가치관(예: '희생'과 '용기')의 구별 정확도를 향상시킴.
- LLM-as-Judge: 사람의 수동 개입 없이 대량의 생성형 콘텐츠 품질 기준선(Baseline)을 자동화된 루브릭 평가 체계로 일정하게 유지함.

연령별 텍스트 조정 기준 지표

프롬프트 내에 구체적인 가이드라인을 주입하여 세대별 인지 발달에 맞춘 출력을 제어하였다.

- 3~5세 (영아): 일상 어휘 위주, 문장당 10단어 이내의 단순 반복 구조, 의성어·의태어 극대화.

- 6~8세 (유아): 감정 표현 어휘 포함, 문장당 15단어 이내, 원인-결과 구조 및 자연스러운 교훈 도출.
- 9~11세 (아동): 확장 어휘 및 일부 관용 표현 허용, 문장당 20단어 이내, 복선과 조연의 감정 묘사 포함.

2.3 다국어(영어) 동화 생성 및 병렬 저장 구조

영어 동화 서비스는 단순한 기계 번역이 아닌, 글로벌 아동 언어 기준인

CEFR(유럽공통언어참조기준)을 프롬프트에 명시하여 '원어민 아동 수준의 자연스러운 표현 방식'으로 직접 재작성(Age-appropriate English rewrite)하는 전략을 취했다.

- 품질 기준: 영아/유아용은 CEFR A1~A2 수준, 아동용은 A2~B1 수준 적용.
- 저장 및 TTS: Supabase stories 테이블 내에 content_ko와 content_en 컬럼을 병렬로 분리 저장하고, ElevenLabs의 eleven_multilingual_v2 모델이 가진 언어 자동 감지 기능을 활용해 단 하나의 Voice ID로 두 언어를 모두 이질감 없이 합성하도록 설계했다.

2.4 Voice Cloning 및 Neural TTS 모듈 분석

본 서비스의 핵심인 목소리 복제는 ElevenLabs의 Few-shot Speaker Adaptation 방식을 채택했다. 사전 학습된 대형 Speaker Encoder가 사용자가 녹음한 30~60초의 오디오 샘플에서 화자의 고유 음색, 억양, 호흡 패턴이 담긴 d-vector(화자 임베딩)를 추출한다. 이후 전체 모델 가중치를 파인튜닝(Fine-tuning)하지 않고, Acoustic Model 단계에 해당 임베딩 벡터만 주입·교체하여 실시간에 가까운 오디오 합성을 실현한다.

기술 선택 트레이드오프: ElevenLabs API vs XTTS-v2 오픈소스

- 한국어 음질 및 운율: XTTS-v2는 한국어 지원 시 억양의 어색함이 남았으나, ElevenLabs는 상용 수준의 자연스러운 한국어 G2P 및 운율을 보장하여 핵심 가치 구현에 적합했다.
- 인프라 및 개발 비용: 오픈소스 구동을 위한 고성능 GPU 서버 인프라 구축 대신 API 종량제 과금 방식을 선택하여 PoC 단계의 운영 비용과 리소스를 최소화했다.

Ⅲ. 서비스 개발 및 최종 구현 결과


3.1 팀원별 역할 분담 및 마일스톤 달성

- 김현정: 서비스 아키텍처 기획, Claude 파이프라인 기반 연령별 동화 54편 생성 및 Supabase DB 세팅 완료.
- 최지은: Make를 통한 Webhook 인프라 연동, ElevenLabs 클로닝 API 파이프라인 자동화 구현.
- 최지은, 김국희: Bolt.new와 Claude, Cursur 페어 프로그래밍을 활용한 모바일 반응형 웹 화면 프론트엔드 전체 구현.
- 김국희: 최종 결과물 검증, 사용자 대상 베타 테스트 진행 및 발표 자료 작성.

3.2 바이브 코딩(Vibe Coding) 중심의 프론트엔드 구현

Claude, Cursur AI 및 Bolt.new 툴과의 지속적인 프롬프트 피드백(Vibe Coding)을 통해, 디자인 컴포넌트 설계 없이도 직관적이고 완성도 높은 모바일 브라우저 전용 웹앱 화면을 구현했다.

- 메인페이지 화면: 회원가입 및 로그인, 서비스 소개와 목소리녹음 단계 설명, 사용자 후기를 제공하여 서비스 사용을 독려한다.



FEATURES

이런 게 가능해요



내 목소리 만들기

30초만 녹음하면 얼마 아바 목소리를 AI가 똑같이 배워요.



AI 동화 만들기

줄거리만 알려주면 우리 아이가 주인공인 동화를 만들어줘요.



내 목소리로 들려주기

전래동화부터 영어동화까지, 부모님 목소리로 읽어줘요.



잠자기 타이머

정한 시간이 지나면 자정으로 멈춰요. 잠자리 동화에 딱이에요.

HOW IT WORKS

3단계로 끝나요

01

목소리 녹음

짧은 문장 몇 개를 포착도백 읽어주세요. 1분이면 충분해요.

02

동화 고르기

전래동화-세계명작-영어동화, AI가 만든 동화까지 마음껏 골라요.

03

들려주기

엄마 아바 목소리로 동화가 시작돼요. 끝이 없어도 늘 함께해요.

VOICES

부모님들의 이야기

★★★★★

"제 목소리로 동화를 들려주니 아이 잠투장이 확 좋았어요. 출장 가서도 매일 밤 한 편씩 들려줄 수 있어 좋아요."

5살 아이 엄마

★★★★★

"녹음은 1분이면 끝나는데, 이제 아이가 매일 '아바'가 읽어주는 책'을 먼저 찾아요."

6살 아이 아바

★★★★★

"멀리 계신 할머니 목소리로도 만들어 드렸더니 온 가족이 정말 좋아했어요."

4살 아이 엄마

오늘 밤, 한 편 들려줄까요?

지금 가입하면 바로 우리 아이만의 동화를 시작할 수 있어요.

무료로 시작하기 →

마이보이스스토리 for kids

엄마 아바 목소리로 들려주는 우리 아이 동화


시강대학교 · 생생형 AI의 이해와 활용 9조 프로젝트

© 2024 MyVoiceStory for kids


- 동화만들기 화면: 아이 정보와 원하는 이야기를 단순한 1,2 문장으로 입력하여 완성된 이야기를 AI를 통해 자동으로 만들 수 있다.


- 목소리 녹음 화면: Web Audio API를 활용해 브라우저 상에서 마이크 권한을 획득하고, 가이드 스크립트를 보며 실시간으로 녹음할 수 있는 인베디드 UI 구축한다. 가이드 스크립트는 6개 정도의 짧은 문장으로, 단시간에 목소리를 녹음할 수 있도록 한다.

- AI 복제 및 재생 화면: 녹음 완료 시 자동으로 오디오 데이터가 백엔드로 전송되며, 합성이 완료되면 플레이어 컴포넌트를 통해 목소리를 선택가능하다.



- 동화 목록/상세 화면: 연령별 태그 및 교훈별 필터링이 가능하다. 동화에 대한 원문확인과 목소리 선택기능이 노출된다.





3.3 백엔드 인프라 및 API 연동 결과

Make 자동화 시나리오를 중심 축으로 하여 유기적인 오디오 생성 파이프라인을 연동했다.

- 사용자가 웹 화면에서 녹음 완료 버튼을 누르면 오디오 바이너리 데이터가 Webhook을 통해 Make 서버로 트리거된다.
- Make 시나리오는 해당 데이터를 ElevenLabs Instant Voice Cloning API로 전송하여 고유한 Voice ID를 발급받고, 이를 Supabase 유저 테이블에 매핑한다.
- 유저가 동화 재생을 요청하면, 선택된 동화 텍스트와 Voice ID가 ElevenLabs TTS 합성 API로 넘어가 음성 파일로 변환된 후 Cloudflare R2 스토리지에 최종 업로드된다.

IV. 베타 테스트 및 검증 (Evaluation & Feedback)

4.1 실사용자 베타 테스트 수행 환경

구현된 PoC 모델의 안정성과 음성 품질을 검증하기 위해, 영유아 및 초등 저학년 자녀를 둔 지인 가정 5가구를 대상으로 베타 테스트를 실시했다. 각 가정의 보호자 목소리를 현장에서 직접 녹음한 뒤 생성된 텍스트 기반 동화를 아이들에게 들려주고 피드백을 수집했다.

4.2 시스템 정량적/정성적 성능 평가

- 동화 추천 및 DB연동 안정성 : Claude 파이프라인을 통해 사전 구축된 동화 콘텐츠 데이터가 Supabase DB와 동기화됨을 확인하였다. 특히 사용자가 프론트엔드에서 자녀의 연령대 및 특정 교훈 키워드를 선택했을 때, 매핑된 조건에 부합하는 타깃 동화 리스트가 지연시간 0.3초 이내로 정확히 필터링되어 추천 세션이 정상 작동함을 검증하였다.
- 음성 유사도 및 자연스러움: ElevenLabs의 Few-shot Speaker Adaptation 메커니즘을 통해, 30~60초의 짧은 샘플 음성만으로도 해당 목소리로 다양한 동화를 구연할 수 있었다..
- 다국어 전환 안정성: 한국어 목소리로 생성된 동일 Voice ID 상태에서 영어 동화를 재생했을 때에도, 영어로의 연동이 어려웠다.

4.3 시스템 트러블슈팅 및 예외 처리 (Troubleshooting)

예상 및 도출된 문제	원인 진단 절차	대응 방안 및 예외 처리 결과
AI 복제 음성의 동화구연 속도 조절 오류 : 목소리 복제 자체는 성공했으나, 합성된 오디오가 실제 목소리보다 빠른 속도로 생성되어 어색함.	① ElevenLabs TTS API 요청 페이로드(Payload)의 파라미터 설정 값 조사 ② 복제된 Voice ID 고유의 화자 임베딩 데이터가 가진 발화 속도(Speaking Rate) 기본값 분석	① ElevenLabs API의 voice_settings 내 stability 및 similarity_boost를 동화 구연 목적에 맞게 하이퍼파라미터 튜닝 ② Claude 스크립트 전처리 파이프라인 단계에서 문장 간 멈춤을 강제하기 위해 SSML 태그(예: <break time="1.0s"/>) 또는 마침표/쉼표 가중치 프롬프팅 적용

녹음 가이드 스크립트 제어 오류 : 30초 녹음 기준 충족용 '5문장 순차 추천' 기획 중 프론트엔드 로직 오류 발생 한 문장 읽고 버튼을 누르면 다음 문장으로 넘어가야 하나, 30초 이상 채워야만 다음 버튼이 활성화되어 UX 병목 유발	① 녹음 컴포넌트 내 Next_Button 활성화 조건문 소스코드 분석 ② 문장 전환 트리거와 전체 누적 녹음 시간 변수의 종속성 검증 ③ 개별 스크립트 완료 이벤트가 전체 세션 타임아웃 로직과 혼선됨을 확인	① 상태 변수 분리: 누적 녹음 시간 변수와 개별 문장 단계 진행 플래그를 독립된 State로 분리 선언 ② 조건 세분화: '다음 문장' 버튼은 문장 낭독 완료 즉시 트리거되게 수정하고, 최종 '복제 요청' 버튼만 30초 이상일 때 활성화 ③ 가이드 문장을 읽으며 자연스럽게 30초를 채우는 최적의 데이터 수집 UX 안착
크로스링구얼(영어) 음성 합성 연동 오류 (미해결) 한국어 샘플로 생성된 Voice ID 상태에서 영어 동화 스크립트 재생 시, 영어 음성 합성이 아예 연동되지 않거나 비정상적인 발음이 출력되는 시스템 오류 발생	① ElevenLabs API 모델 파라미터 확인 (eleven_monolingual_v1 오지정 여부 체크) ② 한국어 화자 임베딩 데이터(d-vector)의 다국어 음소(Phoneme) 매핑 테이블 및 G2P 호환성 프로파일링 ③ API 호출 시 다국어 전용 엔드포인트 세션의 토큰 누수 및 언어 자동 감지(Language Detection) 오류 진단	[원인 진단]: 초기 설정된 단일 언어 모델의 한계 및 한국어 음색 특징이 영어 음소 가중치와 충돌하여 다국어 모델(eleven_multilingual_v2)로의 전환 연동 실패 확인 [현재 상태]: 본 PoC 단계에서는 영어 연동 문제를 최종 해결하지 못해 미해결 한계점으로 분류함 [향후 개선 계획]: 차기 고도화 단계에서 다국어 파라미터를 명시적으로 강제 지정을 하는 API 요청 페이로드 디버깅 및 영어 전용 녹음 샘플(이중 학습 방식)을 추가 수집하여 하이브리드 Voice ID 매핑 구조로 개선 예정

V. 기술적 한계점 및 향후 개선 방향

5.1 현재 시스템의 기술적 한계 분석

- 감정 표현의 제한: 현재의 Few-shot 임베딩 방식은 화자의 고유 음색은 훌륭히 복제하나, 동화 구연 특유의 극적인 감정 변화(구절에 따른 긴장감, 슬픔, 과장된 톤)를 완벽히 표현하지 못하고 다소 평탄한 조로 읽는 한계가 존재한다.
- 데이터 주권 및 비용 종속성: 핵심 파이프라인이 외부 상용 인프라(ElevenLabs)에 완전히 종속되어 있어 유저 스케일업 시 API 비용 부담이 선형적으로 증가하며, 목소리 생체 데이터의 외부 전송에 따른 보안적 한계가 존재한다.

5.2 기술 아키텍처 고도화 로드맵

- 컨텍스트 기반 Emotional TTS 자동화: 향후 고도화 단계에서는 동화 스크립트의 장면별 감정 상태(기쁨, 슬픔, 공포 등)를 LLM이 선제적으로 분석하여 메타데이터 태그로 주입하고, 감정 조절 파라미터와 동적 결합하여 오디오의 극적 완성도를 높일 예정이다.
- 오픈소스 기반 온프레미스(Self-hosting) 인프라 전환: 서비스 규모 확장 시 데이터 보안 확보 및 API 비용 제로화를 위해 완전 자체 GPU 인프라 내에 오픈소스 음성 합성 모델인 XTTS-v2를 호스팅하는 구조로 전환 로드맵을 수립한다.
- Prompt-to-Story 파이프라인 확장: 보호자가 원하는 몇 가지 핵심 키워드나 줄거리를 입력하면 LLM이 맞춤형 동화를 창작하고, 즉시 복제된 목소리로 연결되어 재생되는 '사용자 맞춤형 생성 파이프라인'을 연동할 기술적 타당성을 검토한다.

VI. 결론 (Conclusion)

본 프로젝트는 생성형 AI의 양대 축인 대형 언어 모델(LLM)과 음성 복제(Voice Cloning) 기술을 결합하여, 단순한 텍스트 소비를 넘어 기술에 감성적 가치를 불어넣는 인공지능 육아 지원 인프라를 성공적으로 구현시켰다. 비록 상용 API 종량제 비용과 감정 표현력의 한계라는 과제가

남아있으나, 노코드 및 바이트 코딩을 통해 아주 짧은 시간 안에 복잡한 엔드투엔드 파이프라인을 구축하고 실제 필드 테스트에서 유의미한 사용자 피드백을 이끌어냈다는 점에서 기술적 구현의 가치가 매우 크다고 평가된다. 향후 오픈소스 모델 고도화 및 캐싱 최적화를 통해 시스템 안정성을 강화해 나갈 것이다.